Projeto 3: Autoencoder Variacional (VAE) em Fashion-MNIST

Disciplina: Introdução às Redes Neurais Artificiais

Autor(es): Thiago Roberto Fernandes Rocha (RA: 149.641)

Repositório / Código Reprodutível: https://github.com/ThiagoRberto/redes_neurais

1. Configuração Experimental e Reprodutibilidade

1.1. Dados, Extração e Pré-processamento

Foi utilizado o conjunto Fashion-MNIST: imagens em tons de cinza de 28×28 pixels de dez classes de vestuário (camiseta, calça, pulôver, vestido, casaco, sandália, camisa, tênis, bolsa e bota). Cada imagem é achatada em um vetor $\mathbf{x} \in [0,1]^{784}$, dividindo-se os níveis de cinza por 255. Os 60 000 exemplos de treino oficiais foram divididos, de forma estratificada e com semente 42, em 50 000 para treino e 10 000 para validação; os 10 000 exemplos do conjunto de teste oficial foram usados apenas na avaliação final (Tabela 1).

Tabela 1: Partição dos dados. Todos os conjuntos são balanceados entre as classes.

Conjunto	**Imagens**	**Por classe**
Treino	50 000	5 000
Validação (seleção de hiperparâmetros e early stopping)	10 000	1 000
Teste (avaliação final e análise do espaço latente)	10 000	1 000

1.2. Modelo

O VAE foi implementado em PyTorch (arquivo `vae.py`) com codificador e decodificador do tipo MLP. O codificador aplica camadas densas com ativação aos 784 pixels e termina em duas camadas lineares paralelas, que produzem a média $\boldsymbol{\mu}(\mathbf{x})$ e o logaritmo da variância $\log \boldsymbol{\sigma}^2(\mathbf{x})$ do posterior aproximado $q(\mathbf{z} \mid \mathbf{x}) = \mathcal{N}(\boldsymbol{\mu}, \mathrm{diag}(\boldsymbol{\sigma}^2))$, com $\mathbf{z} \in \mathbb{R}^d$ e $d \in \{2, 8\}$. A amostragem usa o truque da reparametrização, $\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\sigma} \odot \boldsymbol{\epsilon}$ com $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$. O decodificador espelha o codificador (as mesmas camadas ocultas em ordem inversa) e termina em 784 logits, aos quais se aplica a sigmoide para obter as intensidades reconstruídas. A priori é $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$.

A função de custo é o negativo do limite inferior da evidência (*ELBO*) por imagem, com peso $\beta = 1$ sobre o termo de divergência:

$$\mathcal{L}(\mathbf{x}) = \underbrace{-\sum_{i=1}^{784} \Big[x_i \log \hat{x}_i + (1 - x_i) \log(1 - \hat{x}_i) \Big]}_{\text{reconstrução (entropia cruzada binária)}} + \underbrace{\tfrac{1}{2} \sum_{k=1}^{d} \Big(\mu_k^2 + \sigma_k^2 - \log \sigma_k^2 - 1 \Big)}_{D_{\mathrm{KL}}(q(\mathbf{z}|\mathbf{x}) \,\|\, p(\mathbf{z}))}, \tag{1}$$

em que $\hat{x}_i$ é a saída do decodificador. O primeiro termo mede o quanto a imagem reconstruída difere da original. O segundo, o KL, mede o quanto a distribuição que o codificador atribui a cada imagem difere da distribuição $\mathcal{N}(\mathbf{0}, \mathbf{I})$; seu valor, em nats, indica quanta informação sobre a imagem o código $\mathbf{z}$ carrega. Os dois termos competem: reconstruir melhor exige usar mais informação do espaço latente (mais KL), enquanto o KL empurra todas as imagens para uma região comum, o que torna o espaço contínuo e permite gerar imagens novas. Todas as perdas são reportadas em *nats* por imagem (soma sobre os pixels e média sobre as imagens). O treino usa o otimizador Adam, com sorteio novo da ordem das amostras a cada época, e ***early stopping***: o treino é interrompido quando a perda de validação não melhora por p épocas consecutivas (paciência) e os pesos da melhor época são restaurados. Para que as perdas de validação e de teste sejam comparáveis entre modelos, o ruído $\boldsymbol{\epsilon}$ usado na avaliação é gerado por uma semente fixa.

1.3. Métricas de Avaliação

A **perda de validação** (e, na avaliação final, de teste) é o valor de $\mathcal{L}$ acima, médio sobre o conjunto, decomposto em reconstrução e KL. Para explorar o espaço latente, cada imagem do conjunto de teste é representada pela média do posterior, $\boldsymbol{\mu}(\mathbf{x})$, e são calculados:

- **PCA:** ajustado às médias $\boldsymbol{\mu}$ do conjunto de treino e aplicado às do teste; para $d = 8$ fornece a projeção em 2D e a fração de variância explicada por cada componente.
- **Unidades ativas:** dimensões latentes cuja variância de μ_k entre as imagens excede 0,01; dimensões abaixo desse limiar valem quase o mesmo para todas as imagens, ou seja, o modelo as ignora (fenômeno chamado de colapso do posterior).
- **Separação dos rótulos:** o *silhouette* (de -1 a 1) mede se cada ponto está mais próximo da sua própria classe do que das outras; valores perto de 0 indicam classes sobrepostas. A acurácia do k-NN ($k = 5$, ajustado nas representações do treino e avaliado nas do teste) indica o quanto a classe de uma imagem pode ser lida a partir dos vizinhos no espaço latente. O NMI e o ARI (de 0 a 1) medem o quanto os 10 grupos encontrados por um k-means, que não vê os rótulos, coincidem com as classes reais. Essas métricas servem para quantificar o que se vê nos gráficos; os rótulos não são usados no treino do VAE.

1.4. Busca de Hiperparâmetros e Critério de Seleção

A Tabela 2 resume o espaço explorado. A busca foi uma grade completa, feita **separadamente** para cada dimensão latente, pois a arquitetura pode variar com d: 6 topologias $\times$ 2 ativações $\times$ 2 taxas de aprendizado $\times$ 2 tamanhos de lote $\times$ 2 sementes (42 e 43), ou seja, 96 treinos por dimensão e 192 no total. Cada configuração é resumida pela média das duas sementes e todas as tentativas foram registradas no arquivo de log (`busca_vae.csv`). Cada treino teve no máximo 80 épocas e paciência 8.

Tabela 2: Hiperparâmetros explorados na busca e valores escolhidos. As topologias listam os tamanhos das camadas ocultas do codificador (o decodificador as espelha).

Hiperparâmetro	**Valores explorados**	**Escolhido** ($d = 2$)	**Escolhido** ($d = 8$)
Camadas ocultas	[256], [512], [512,256], [1024,512], [512,256,128], [1024,512,256]	[512,256,128]	[1024,512]
Ativação	ReLU, tanh	tanh	ReLU
Taxa de aprendizado	10^{-3}, 5×10^{-4}	5×10^{-4}	5×10^{-4}
Tamanho do lote	128, 256	256	256

Fixos: otimizador Adam, $\beta = 1$, busca com no máximo 80 épocas e paciência 8.

Critério de seleção. Para cada dimensão latente, escolhe-se a configuração de **menor perda de validação média** (as duas sementes), conforme pedido no enunciado. A Tabela 3 traz as configurações escolhidas e o número de parâmetros. A avaliação final (Seção 3) retreina cada uma com 5 sementes (42 a 46) e **até 200 épocas**, com a mesma paciência de 8: na busca, 43% dos treinos de $d = 2$ e 65% dos de $d = 8$ terminaram por atingir o limite de 80 épocas, isto é, ainda estavam melhorando, e por isso o orçamento foi ampliado na avaliação final.

Tabela 3: Configurações selecionadas. A perda de validação da busca é a média de 2 sementes (80 épocas); a da avaliação final, de 5 sementes (até 200 épocas).

d	**Camadas ocultas**	**Ativação**	**lr**	**Lote**	**Parâmetros**	**Perda de val. (busca / final)**
2	[512, 256, 128]	tanh	5×10^{-4}	256	1 133 844	250,45 / 250,49
8	[1024, 512]	ReLU	5×10^{-4}	256	2 670 368	235,35 / 235,09

2. Dinâmica de Treinamento e Convergência

A Figura 1 mostra, para as duas dimensões latentes, a evolução da perda total, do termo de reconstrução e da divergência KL no treino e na validação (semente 42, avaliação final).

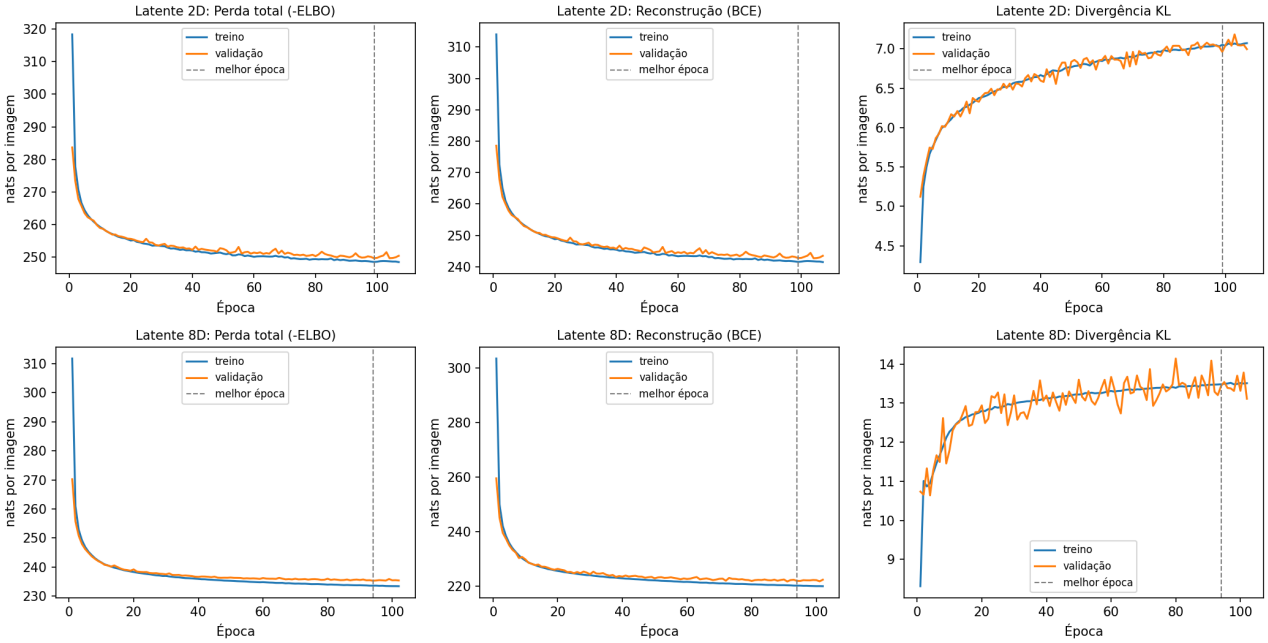


Figura 1: Curvas de treino e validação do VAE com espaço latente 2D (acima) e 8D (abaixo), semente 42. A linha tracejada marca a melhor época, cujos pesos são restaurados.

Análise Crítica da Dinâmica de Convergência:

- **Convergência:** a perda cai de forma muito rápida nas primeiras 10 épocas (de cerca de 310 a 320 para menos de 260 nats no treino) e depois decresce lentamente. Na avaliação final, com até 200 épocas, a melhor época ficou entre 54 e 99 ($d = 2$) e entre 91 e 123 ($d = 8$), e todos os 10 treinos terminaram por *early stopping* (62 a 107 e 99 a 131 épocas). O ganho em relação ao treino de 80 épocas foi pequeno, de cerca de 0,25 nat na perda de teste média (252,61 para 252,36 em $d = 2$ e 237,08 para 236,82 em $d = 8$).
- **Reconstrução × KL:** enquanto a reconstrução diminui, o KL *aumenta* ao longo do treino (de cerca de 4 e 8 nats na primeira época para 7 e 13 nats, em $d = 2$ e $d = 8$), pois o modelo passa gradualmente a usar mais informação do espaço latente para reconstruir melhor. O KL de $d = 8$ é cerca do dobro do de $d = 2$ e a validação oscila mais nele (curva laranja) do que na perda total.
- **Generalização:** as curvas de treino e validação ficam muito próximas, com uma diferença de poucos nats na melhor época (1,0 em $d = 2$ e 1,5 em $d = 8$ nas médias da busca), sem sinal de sobreajuste. O *early stopping* atua, na prática, como critério de parada por estagnação da validação.
- **Variabilidade:** o desvio padrão da perda de validação entre sementes é pequeno: 0,64 nat ($d = 2$) e 0,18 nat ($d = 8$) na avaliação final com 5 sementes, e em média 0,4 e 0,5 nat entre as duas sementes da busca.

3. Resultados e Desempenho Comparativo ($d = 2$ × $d = 8$)

3.1. Função de custo no conjunto de teste

A Tabela 4 reúne as métricas finais. O VAE com espaço latente 8D obteve perda de teste 15,5 nats (6,2%) menor que o de 2D, ou seja, uma redução de 22,1 nats no termo de reconstrução, parcialmente

compensada por 6,5 nats a mais de KL: com mais dimensões o modelo transmite mais informação por imagem (maior KL) e reconstrói melhor. A Figura 2 compara reconstruções e a Figura 3 mostra amostras geradas pela distribuição a priori.

Tabela 4: Resultados finais no conjunto de teste (média ± desvio padrão de 5 sementes, em nats por imagem).

	Latente 2D	**Latente 8D**
Perda total (−ELBO)	252,36 ± 0,64	236,82 ± 0,18
Reconstrução (entropia cruzada)	245,46 ± 0,72	223,39 ± 0,45
Divergência KL	6,90 ± 0,08	13,43 ± 0,30
Perda de validação	250,49 ± 0,64	235,09 ± 0,18
Unidades latentes ativas	2	7,2 ± 0,4
Parâmetros	1 133 844	2 670 368
Épocas treinadas	87,0 ± 16,3	107,2 ± 13,4

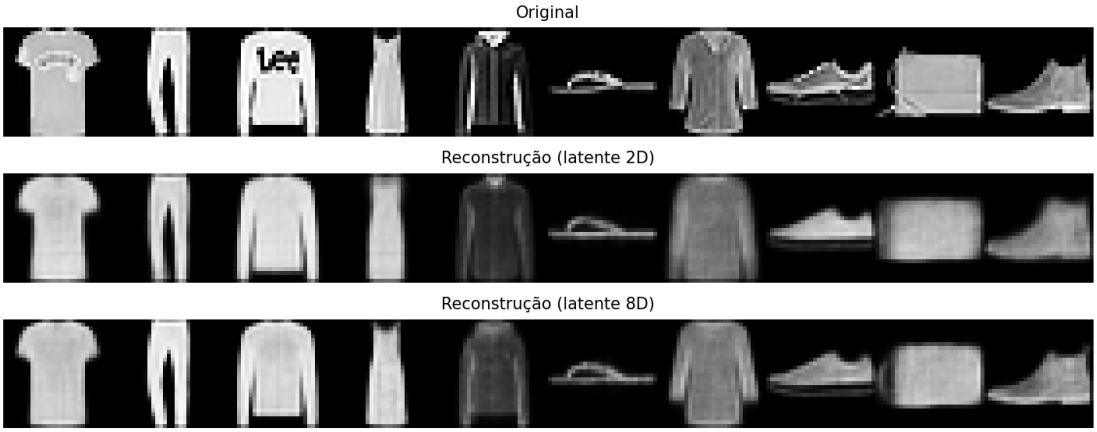


Figura 2: Imagens de teste originais (uma por classe) e suas reconstruções $\sigma(\text{decodificador}(\boldsymbol{\mu}))$ pelos VAEs com espaço latente 2D e 8D (semente 42).

Observações.

- **Reconstruções:** ambos os modelos preservam a silhueta, o brilho global e a classe, mas suavizam os detalhes finos (o texto da camiseta, as listras do casaco). O modelo 8D recupera mais detalhes (alças do vestido, mangas, o solado do tênis e da bota), enquanto o 2D tende a produzir um protótipo da região do espaço latente onde a imagem caiu (por exemplo, a camisa de mangas longas, que sai borrada).
- **Geração:** as amostras da priori são nítidas o bastante para identificar a classe nos dois modelos. As do 8D são mais variadas em detalhes (sandálias, bolsas com alça, camisetas de tons diferentes) e algumas são ambíguas ou com textura irregular, o que indica regiões da priori que o decodificador cobre mal.

3.2. Exploração do espaço latente

A Figura 4 mostra o espaço latente 2D do conjunto de teste, colorido pelo rótulo, e a Figura 5 mostra a projeção por PCA do espaço 8D. O decodificador aplicado a uma grade de pontos do espaço 2D (Figura 6) revela como o modelo organiza as classes. Os gráficos por classe estão no Apêndice A.

A Tabela 5 quantifica a separação das classes, no espaço latente completo e na projeção em 2D, e a Tabela 6 mostra o desempenho do classificador k-NN por classe.

Há formação de clusters no espaço latente? Em parte. No espaço 2D (Figura 4) as imagens se organizam em regiões compactas e reconhecíveis (calças, bolsas, botas, tênis, sandálias), mas elas

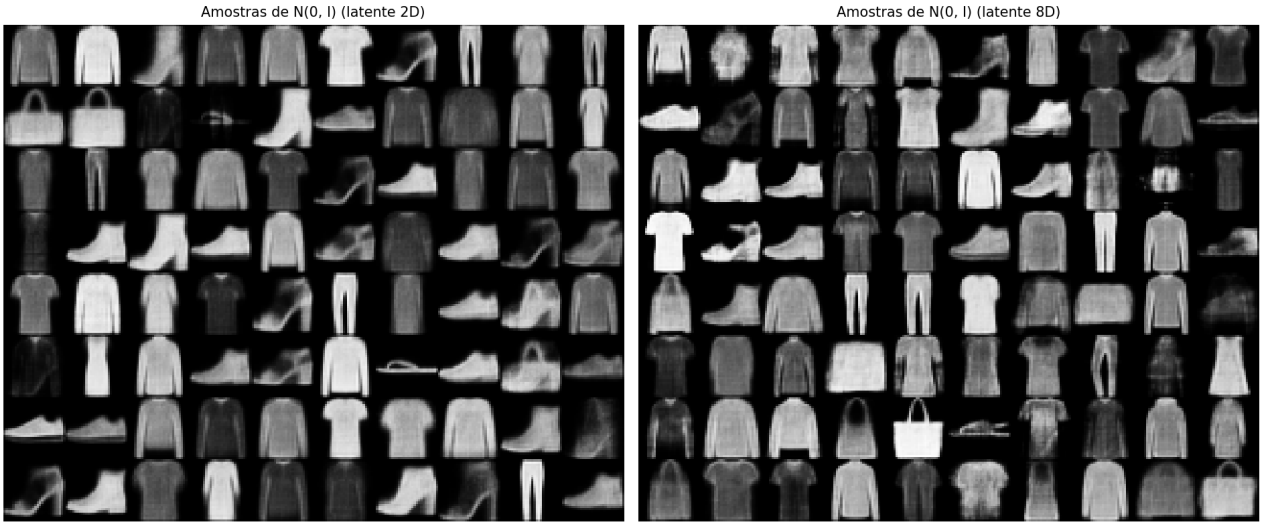


Figura 3: Imagens geradas decodificando $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ (80 amostras por modelo, semente 42).

Tabela 5: Separação dos rótulos no conjunto de teste (média ± desvio padrão de 5 sementes). Para $d = 2$ o espaço latente é a própria projeção. NMI e ARI referem-se a um k-means com 10 grupos.

Modelo	**Representação**	**Silhouette**	**Acurácia k-NN**	**NMI**	**ARI**
$d = 2$	latente 2D	0,086 ± 0,005	0,734 ± 0,010	0,515 ± 0,011	0,350 ± 0,023
$d = 8$	latente 8D completo	0,051 ± 0,007	0,833 ± 0,003	0,483 ± 0,027	0,355 ± 0,028
$d = 8$	projeção PCA 2D	−0,056 ± 0,040	0,374 ± 0,070	0,309 ± 0,073	0,184 ± 0,057

se tocam: não há vazios entre os grupos, e a nuvem toda ocupa aproximadamente a região da priori $\mathcal{N}(\mathbf{0}, \mathbf{I})$, efeito do termo KL, que aproxima as nuvens de todas as imagens. Por isso os agrupamentos são pouco isolados: o *silhouette* dos rótulos é baixo (0,086) e um k-means com 10 grupos recupera os rótulos de modo moderado (NMI 0,52). Duas grandes regiões se destacam: a do calçado (sandália, tênis, bota) e a das peças superiores (camiseta, vestido, pulôver, casaco, camisa); a bolsa forma uma região separada, e a calça ocupa uma faixa própria. No espaço 8D, a projeção em 2D (Figura 5) mostra pouca estrutura de agrupamentos (silhouette negativo, −0,056), mas isso decorre da projeção, e não do espaço: no espaço 8D completo o k-NN atinge 83% de acerto, o que indica que há estrutura de classes que a projeção não preserva.

Há separação dos rótulos no espaço latente? Sim, mas desigual, e a separação segue a semelhança visual das classes. No 2D (Figura 4 e Apêndice A) são bem separadas a calça (recall 0,90), a bolsa (0,92), a bota (0,90) e, em menor grau, o tênis (0,82) e a sandália (0,87), embora as três classes de calçado sejam vizinhas. As classes de peças superiores se sobrepõem fortemente no centro-esquerda: camisa (0,32), casaco (0,47) e pulôver (0,58) são as mais confundidas, e a camisa se espalha pela região das demais. O espaço 8D melhora todas as classes (acurácia k-NN de 0,73 para 0,83) e, principalmente, as classes de peças superiores (casaco de 0,47 para 0,71, pulôver de 0,58 para 0,76, camisa de 0,32 para 0,54), mas a camisa continua sendo a classe mais difícil. Na projeção PCA 2D do espaço 8D a separação cai muito (acurácia k-NN de 0,37): só calça e tênis ficam parcialmente isolados, nas bordas da nuvem (Apêndice A).

A projeção ilustra quanto da variância? A *variância explicada* indica que fração da dispersão total dos pontos fica visível no gráfico 2D. Para $d = 2$ não há perda: os dois eixos são o próprio espaço latente, então o gráfico mostra 100% da variância. Para $d = 8$ a projeção ilustra pouco: as duas primeiras componentes principais (PC1 e PC2) explicam apenas **31,3%** (15,8% e 15,5% na semente 42; média de 5 sementes: 31,4% ± 0,8%), ou seja, cerca de 69% da variação entre as imagens não aparece no gráfico. O motivo está na Figura 6 (direita): a variância se divide quase igualmente entre sete componentes (de 13,0% a 15,8% cada) e a oitava vale praticamente 0% (é a dimensão que colapsou,

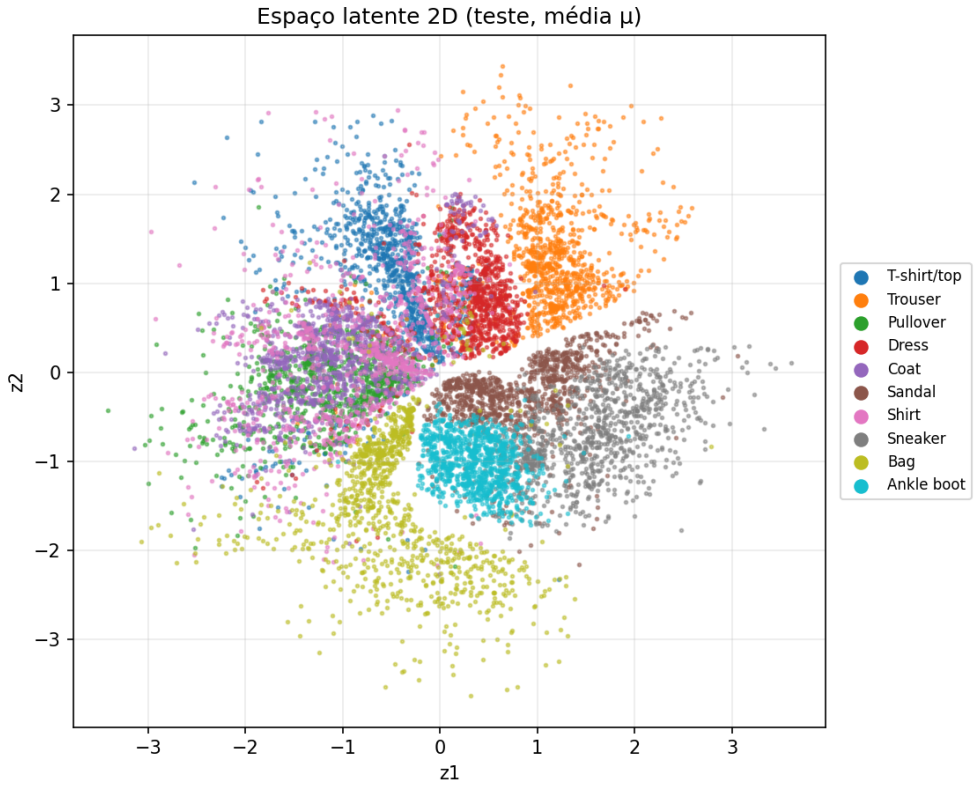


Figura 4: Espaço latente 2D (médias $\boldsymbol{\mu}$ das 10 000 imagens de teste), coloridas pelo rótulo (semente 42).

Tabela 6: Recall do classificador k-NN por classe, no conjunto de teste (média de 5 sementes).

Classe	**2D**	**8D**	**Classe**	**2D**	**8D**
T-shirt/top	0,769	0,815	Sandal	0,866	0,887
Trouser	0,900	0,955	Shirt	0,324	0,541
Pullover	0,579	0,761	Sneaker	0,821	0,930
Dress	0,795	0,854	Bag	0,920	0,945
Coat	0,465	0,714	Ankle boot	0,900	0,932

Figura 7). Em outras palavras, a nuvem de pontos não é mais alongada em nenhuma direção especial, e por isso nenhum par de componentes a resume bem. Isso é esperado em um VAE: o termo KL empurra os pontos para uma gaussiana esférica, com a mesma dispersão em todas as direções. Como consequência, ao reduzir de 8 para 2 dimensões, o PCA sobrepõe classes que estavam separadas nas dimensões descartadas. Por isso a projeção parece mais misturada do que o espaço 8D realmente é: o k-NN acerta 83% no espaço completo e apenas 37% na projeção.

4. Discussão e Lições Aprendidas

Esta seção resume o que a busca de hiperparâmetros e a comparação entre 2D e 8D mostraram. Chamamos de *variação entre sementes* o quanto o resultado muda apenas por trocar o sorteio inicial; diferenças menores que isso não são conclusivas.

- **Arquitetura importa mais que o resto.** Na busca, o fator que mais alterou a perda de validação foi a arquitetura (número e tamanho das camadas ocultas): a diferença entre a melhor e a pior foi de 3,1% ($d = 2$) e 2,3% ($d = 8$), contra menos de 1% para ativação, taxa de aprendizado e tamanho do lote (Tabela 7, Apêndice B). Com $d = 2$, redes de uma única camada oculta ([256] e [512]) ficaram de 7 a 8 nats atrás das mais profundas: com apenas duas dimensões no gargalo, o codificador e o decodificador precisam de mais capacidade para compensar. Entre

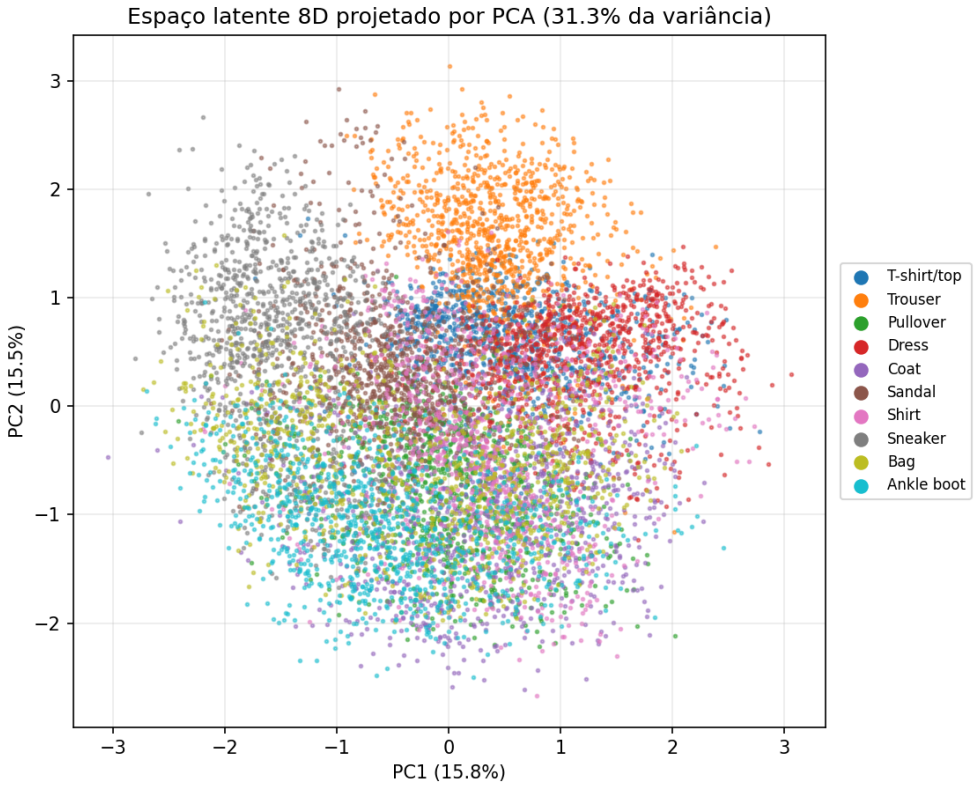


Figura 5: Espaço latente 8D projetado nas duas primeiras componentes principais (PCA ajustado no treino), coloridas pelo rótulo (semente 42). O título indica a variância explicada.

as quatro arquiteturas com duas ou três camadas, a diferença (252,3 a 252,8) é do tamanho da variação entre sementes (0,4 nat), então não dá para dizer qual delas é de fato melhor.

- **A melhor arquitetura depende de d.** Para $d = 2$ foi escolhida a de três camadas ([512,256,128], tanh); para $d = 8$, a de duas camadas largas ([1024,512], ReLU). A arquitetura [512,256,128], a melhor no 2D, foi a pior de todas no 8D (242,2 nats, atrás até das de uma só camada). A ativação teve efeitos opostos: no 2D, tanh foi melhor por apenas 0,3 nat, menos que a variação entre sementes, logo inconclusivo; no 8D, ReLU foi melhor por 2,0 nats, mais que essa variação, logo confiável.

- **Taxa de aprendizado e lote.** A taxa 5×10^{-4} foi um pouco melhor que 10^{-3} (0,3 nat no 2D e 0,8 nat no 8D). Como a taxa menor aprende mais devagar, o limite de 80 épocas da busca a prejudica mais, o que torna essa vantagem, se algo, conservadora. O tamanho do lote quase não alterou a perda (0,06 e 0,24 nat), mas lotes de 128 demoraram cerca de 1,7 vez mais por treino (312 s contra 179 s, em média).

- **Colapso do posterior.** Com $d = 8$, em média só 7,2 das 8 dimensões ficaram ativas: em 4 das 5 sementes, uma dimensão praticamente não varia entre as imagens (variância de μ abaixo de 0,01) e tem KL quase nulo (Figura 7, semente 42). O modelo ignora essa dimensão e a trata como ruído da priori. Com $d = 2$, as duas dimensões são ativas em todas as sementes. Além disso, mesmo com 7 dimensões úteis, o ganho sobre o 2D foi de apenas 6% na perda de teste: aumentar d ajuda, mas com retornos cada vez menores.

- **2D $\times$ 8D.** O espaço 2D pode ser visto diretamente e permite percorrer o decodificador (Figura 6), ao custo de reconstruções menos detalhadas e de classes parecidas (camisa, casaco, pulôver) coladas. O espaço 8D reconstrói melhor e separa melhor as classes, mas só pode ser visualizado por projeções. Como a variância se distribui quase igualmente entre as dimensões, a projeção em 2D descarta cerca de dois terços da informação e esconde boa parte da separação que existe.

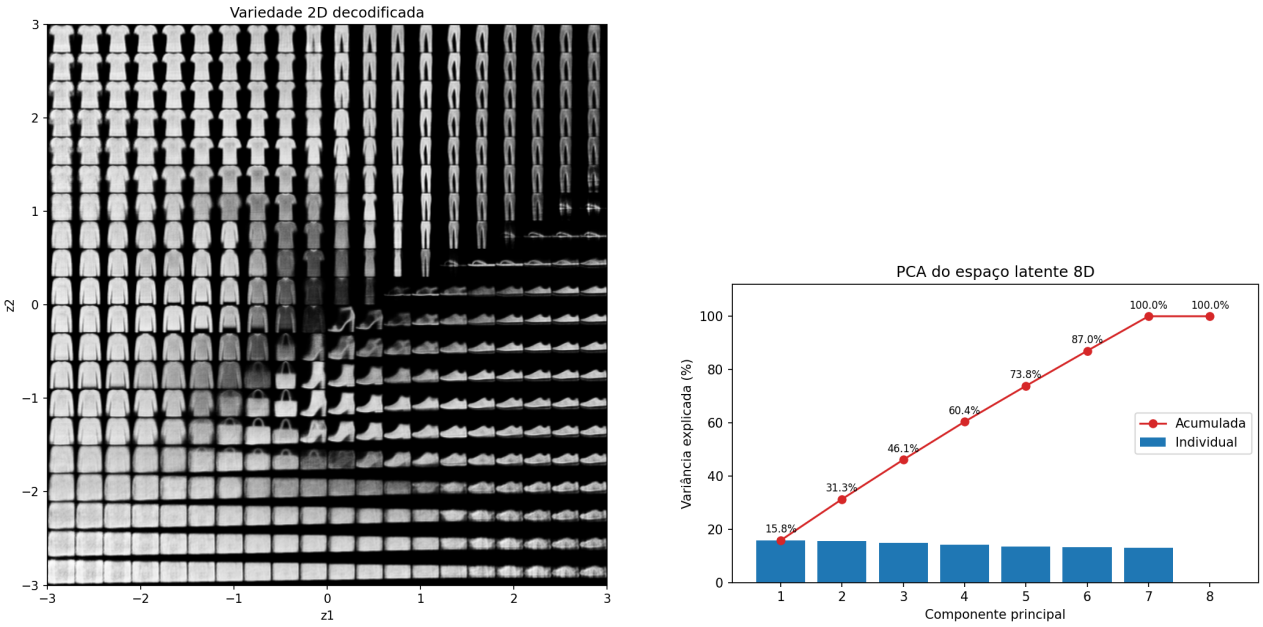


Figura 6: Esquerda: imagens decodificadas em uma grade 20×20 do espaço latente 2D, para $z_1, z_2 \in [-3, 3]$. Direita: variância explicada por cada componente principal do espaço latente 8D (semente 42).

Tabela 7: Perda de validação média por topologia (média de todas as configurações das demais variáveis, 2 sementes) e número de parâmetros. Em negrito, a melhor topologia de cada dimensão.

	Latente 2D		**Latente 8D**	
Camadas ocultas	Parâmetros	Perda de val.	Parâmetros	Perda de val.
[256]	404 244	260,24	408 864	240,57
[512]	807 700	259,52	816 928	239,12
[512, 256]	1 068 820	252,64	1 073 440	237,11
[1024, 512]	2 661 140	252,76	2 670 368	**236,63**
[512, 256, 128]	1 133 844	252,54	1 136 160	242,16
[1024, 512, 256]	2 922 260	**252,35**	2 926 880	239,66

A. Gráficos do Espaço Latente por Classe

As figuras a seguir destacam, em cada painel, uma classe sobre a nuvem completa (em cinza), para o espaço latente 2D e para a projeção PCA do espaço 8D (semente 42).

B. Sensibilidade aos Hiperparâmetros

Perda de validação média ao fixar cada valor de hiperparâmetro e promediar sobre todas as demais configurações da busca.

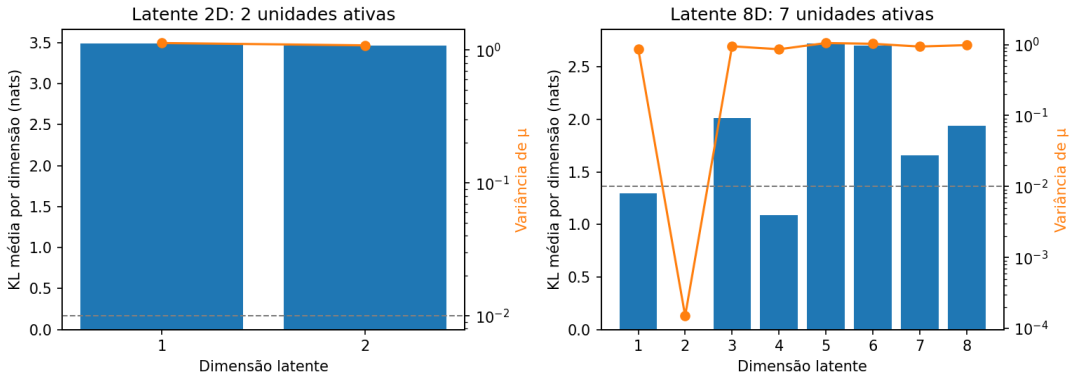


Figura 7: KL média por dimensão latente (barras) e variância de μ (linha, escala logarítmica; tracejado = limiar 0,01) na semente 42. Em $d = 8$ a dimensão 2 colapsou.

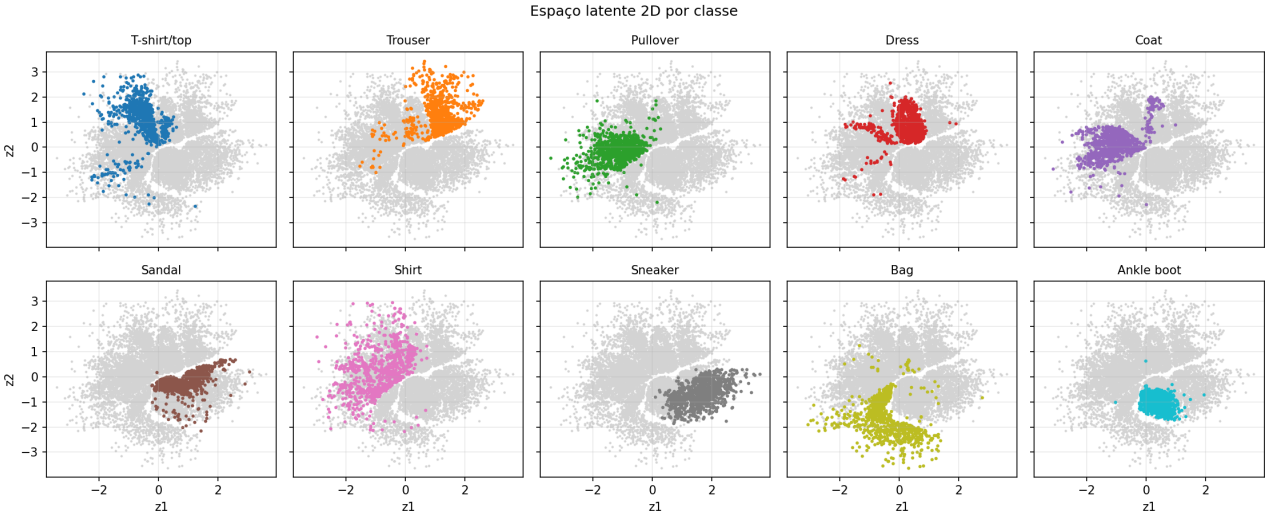


Figura 8: Espaço latente 2D, uma classe por painel.

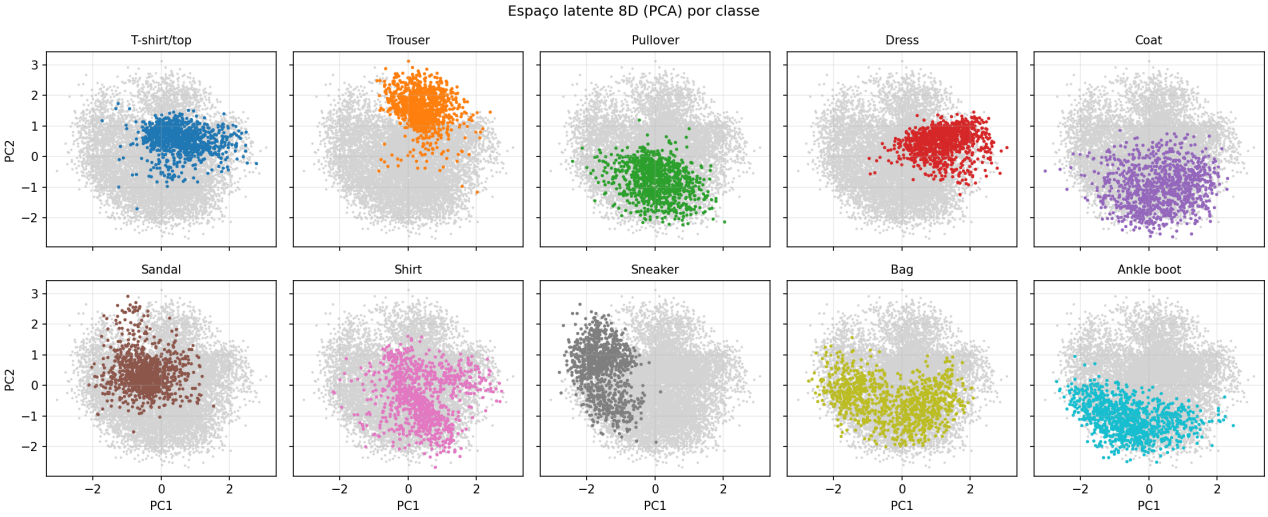


Figura 9: Projeção PCA do espaço latente 8D, uma classe por painel.

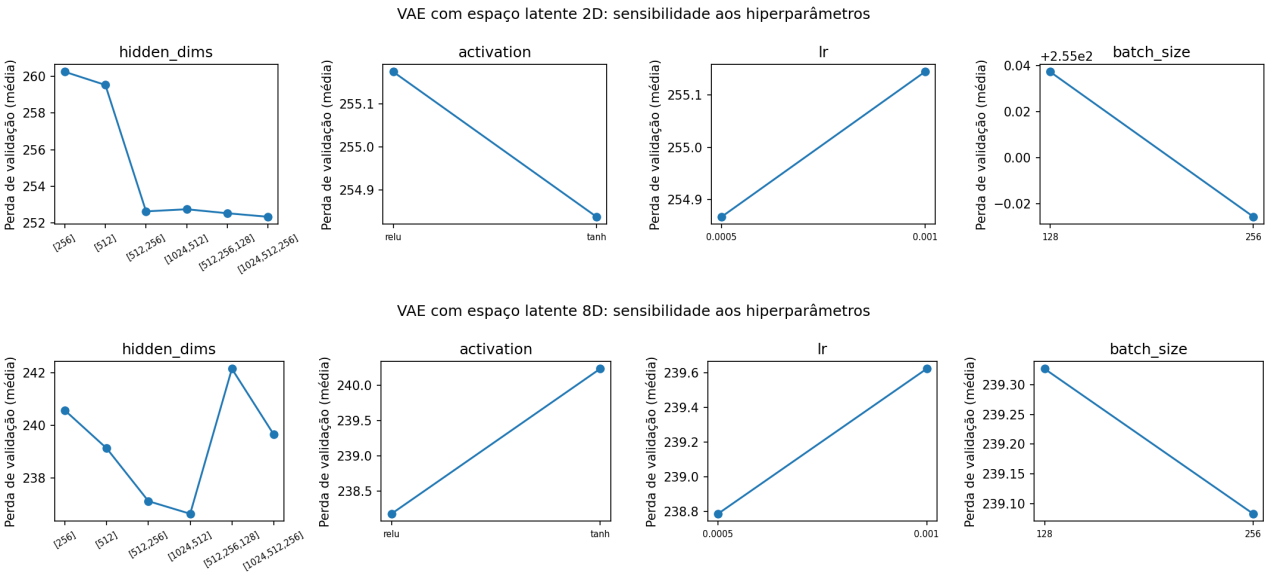


Figura 10: Sensibilidade aos hiperparâmetros da busca para $d = 2$ (acima) e $d = 8$ (abaixo).

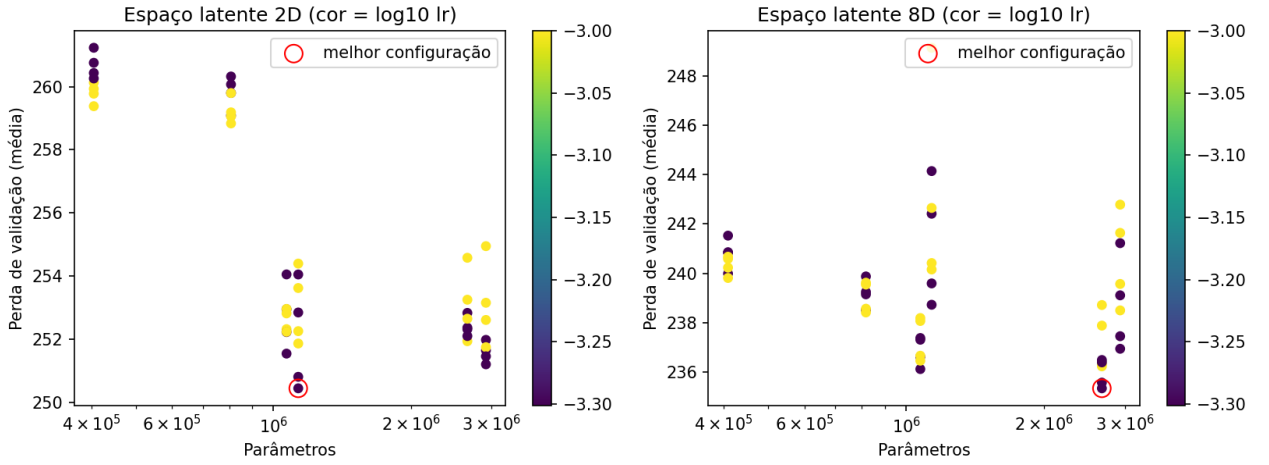


Figura 11: Perda de validação média de cada uma das 96 configurações por dimensão latente em função do número de parâmetros. O círculo vermelho marca a configuração escolhida.